Classification 분류

Introduction to Statistical Learning

황성원

데이터 타입: Quantitative(정량) VS. Qualitative(정성)

Quantitative: 숫자로 표시되는 값


→ 주식 값(1,120원, 1,223원, 1,402원, ...), 성적(66점, 78점, 90점, ...)

Qualitative: 카테고리(또는 Class)로 표시되는 값

→눈의 색깔(파란색, 갈색, 초록색), 환자 상태(뇌졸증, 약물 과다, 간질)


데이터 형태: Quantitative(정량) VS. Qualitative(정성)

Quantitative -> 회귀(Regression) 문제: Fitting하여 값을 추정



데이터 형태: Quantitative(정량) VS. Qualitative(정성)

Qualitative -> 분류(Classification) 문제: Class로 할당(확률: 회귀)



데이터 세트(Dataset): Observed = Training + Test

총 관찰 값들(샘플 수)

훈련 데이터



Test 데이터


성능평가





분류기(분류 모델)

예시: 잔고, 수입 현황 → 채무 불이행 Yes or No



분류문제에 선형 회귀는 적용이 안 될까?

예시: 응급실에 환자가 왔을 때, 환자의 증상을 보고 상태를 예측 입력 출력

정량적 입력: 열의 온도

20도, 25도, 30도...

정성적 입력: 열이 있다 or 없다

이진 변수가 된다.

분류문제에 선형 회귀는 적용이 안 될까?

예시: 응급실에 환자가 왔을 때, 환자의 증상을 보고 상태를 예측 입력 출력


정성적 출력:

뇌졸증 or 약물 과다 복용 or 간질성 발작

분류문제에 선형 회귀는 적용이 안 될까?

예시: 응급실에 환자가 왔을 때, 환자의 증상을 보고 상태를 예측 입력 출력

정량적 출력으로 변환(암호화)!



정성적 출력:

뇌졸증 or 약물 과다 복용 or 간질성 발작

안 되는 이유: 순서 매기기를 통한 오해

$$Y = \begin{cases} 1 \\ 2 \\ 3 \end{cases}$$

여기서 1.5라는 값이 예측되면 무슨 의미일까?

대안: 자연적인 순서를 가지는 출력


Mild or Moderate or Severe



일반적으로, 2개 이상의 Class를 가지는 정성 출력 변수를 정량 변수로 변환 하는 방법_WX

2개!의 정성 출력 변수의 경우!






선형 회귀 방식으로 하기 위해 최소 자승법(Least Squares)를 사용해서 예측해보면,

$$Y \approx \beta_0 + \beta_1 X$$
 \blacksquare $P(약물 과 다 복용 | X)$

위와 같이 계산하는 절차는 LDA(Linear Discriminant Analysis)와 동일!

문제점

1. 마이너스 구역과 1 이상의 구역이 존재



2. Dummy Variable 접근법은 0과 1만을 취하므로 2개 이상의 Class를 가지는 정성적 출력에는 적합하지 않음




Logistic Regression(로지스틱 회귀)

로지스틱 회귀


$$P(au Z) = P(X)$$

Pr(채무불이행=Yes| 잔고) > 0.1/0.5/0.9



로지스틱 모델

$$P(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}$$



$$odds = \frac{P(X)}{1 - P(X)} = e^{\beta_0 + \beta_1 X}$$
 Scale 변환 $0 \sim 1 \rightarrow 0 \sim 9$ 한대

로지스틱 모델

$$odds = \frac{P(X)}{1 - P(X)} = e^{\beta_0 + \beta_1 X}$$

$$\log odds = \log(\frac{P(X)}{1 - P(X)}) = \beta_0 + \beta_1 X$$

Log odds는 X에 대해서 선형이 된다.

회귀 계수 측정 방법

*선형 회귀 ← 최소 자승법 (최대우도법의 특수한 경우)


*로지스틱 회귀 ← 최대우도법

$$l(\beta_0, \beta_1) = \prod_{i:y_i=1} P(x_i) \prod_{i':y_{i'}=0} (1 - P(x_{i'}))$$

R을 이용해서 계산 수행 후 결과.

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-10.6513	0.3612	-29.5	< 0.0001
balance	0.0055	0.0002	24.9	< 0.0001

$$\log odds = \log(\frac{P(X)}{1 - P(X)}) = \beta_0 + \beta_1 X$$




R을 이용해서 계산 수행 후 결과.

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-10.6513	0.3612	-29.5	< 0.0001
balance	0.0055	0.0002	24.9	< 0.0001

$$\operatorname{SE}(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \quad \operatorname{SE}(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

$$\hat{\beta}_1 \approx \beta_1$$



R을 이용해서 계산 수행 후 결과.

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-10.6513	0.3612	-29.5	< 0.0001
balance -	0.0055	0.0002	24.9	< 0.0001

$$\operatorname{SE}(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \quad \operatorname{SE}(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

$$\hat{\beta}_1 \approx \beta_1$$

• • •

How far is far enough? This of course depends on the accuracy of $\hat{\beta}_1$ —that is, it depends on $SE(\hat{\beta}_1)$. If $SE(\hat{\beta}_1)$ is small, then even relatively small values of $\hat{\beta}_1$ may provide strong evidence that $\beta_1 \neq 0$, and hence that there is a relationship between X and Y. In contrast, if $SE(\hat{\beta}_1)$ is large, then $\hat{\beta}_1$ must be large in absolute value in order for us to reject the null hypothesis.

R을 이용해서 계산 수행 후 결과

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)}$$





 $oldsymbol{eta}_1$ 이 얼마나 0으로부터 멀리 떨어졌는지의 표준편차

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-10.6513	0.3612	-29.5	< 0.0001
balance	0.0055	0.0002	24.9	< 0.0001


귀무가설(X,Y간에 관계가 없다)

대립가설(X,Y간에 관계가 있다)





P-value < 0.05



예측 값 계산 해보기

잔고(X)가 1,000인 경우의 채무 불이행 확률은 다음과 같다.

$$\hat{p}(X) = \frac{e^{\hat{\beta}_0 + \hat{\beta}_1 X}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_1 X}} = \frac{e^{-10.6513 + 0.0055 \times 1,000}}{1 + e^{-10.6513 + 0.0055 \times 1,000}} = 0.00576$$

다른 입력(학생여부)일 경우.

학생 여부 → 0과 1로 학생일 때 1, 아닐 때 0으로

이번에는 입력에 대해서 Dummy Variable 접근법을 적용.

		.			
	Coefficient	Std. error	Z-statistic	P-value	
Intercept	-3.5041	0.0707	-49.55	< 0.0001	
student [Yes]	0.4049	0.1150	3.52	0.0004	
$\widehat{\Pr}(\widehat{\texttt{default}} = \widehat{\texttt{Yes}} \texttt{student} = \widehat{\texttt{Yes}}) = \frac{e^{-3.5041 + 0.4049 \times 1}}{1 + e^{-3.5041 + 0.4049 \times 1}} = \underbrace{0.0431},$					
$\widehat{\Pr}(\mathtt{default} = \mathtt{Y})$	es student=No		$41+0.4049\times0$ $5041+0.4049\times0$	= 0.0292.	

W

다변량(여러 입력) 로지스틱 회귀

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$
$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}$$

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-10.8690	0.4923	-22.08	< 0.0001
balance	0.0057	0.0002	24.74	< 0.0001
income	0.0030	0.0082	0.37	0.7115
student[Yes]	-0.6468	0.2362	-2.74	0.0062

SW


학생 여부에 관한 역설적 결과 분석

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-3.5041	0.0707	-49.55	< 0.0001
student[Yes]	0.4049	0.1150	3.52	0.0004

VS.

	Coefficient	Std. error	Z-statistic	P-value
Intercept	-10.8690	0.4923	-22.08	< 0.0001
balance	0.0057	0.0002	24.74	< 0.0001
income	0.0030	0.0082	0.37	0.7115
student[Yes]	-0.6468	0.2362	-2.74	0.0062

Confounding?



로지스틱 회귀(Class가 2개 이상인 경우)


• Discriminant Analysis 에서 다루게 되므로, 따로 다루지 않음.

• R에서 쉽게 구현 가능하다.


LDA (Linear Discriminant Analysis)

Bayes' Theorem

$$P(Y \mid X) = \frac{P(X \mid Y)P(Y)}{P(X)} = posterior = \frac{likelihood \times prior}{evidence}$$




LDA (Linear Discriminant Analysis)



SW

LDA (Linear Discriminant Analysis)




LDA 입력 변수가 p=1개인 경우

$$f_k(x) = P(X = x \mid Y = k)$$

$$f_k(x) = P$$

$$P(Y = k \mid X = x) = \frac{f_k(x) \times \pi_k}{\sum_{l=1}^K \pi_l f_l(x)}$$
 가정 1 Normal or Gaussian Distribution

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{1}{2\sigma_k^2}(x-\mu_k)^2\right)$$




LDA 입력 변수가 p=1개인 경우

$$f_k(x)=P$$

$$P(Y=k\mid X=x)=rac{f_k(x) imes\pi_k}{\sum_{l=1}^K\pi_lf_l(x)} ext{ timegoud for finite quadrates}$$
가정 2 각 Class에서의 분산이 동일!

$$\sigma_1^2 = \ldots = \sigma_K^2$$





LDA 입력 변수가 p=1개인 경우

$P(Y = k \mid X = x) = \frac{f_k(x) \times \pi_k}{\sum_{l=1}^{K} \pi_l f_l(x)}$ Distribution

Normal or Gaussian Distribution

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left(-\frac{1}{2\sigma_k^2}(x-\mu_k)^2\right)$$



각 Class에서의 분산이 동일!





$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_l)^2\right)}$$

양변 Log

discriminant functions


$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$

회귀 계수 측정 방법

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i = k} x_i$$


$$\hat{\sigma}^2 = \frac{1}{n - K} \sum_{k=1}^K \sum_{i:y_i = k} (x_i - \hat{\mu}_k)^2$$

$$\hat{\pi}_k = n_k/n$$




$$\hat{\delta}_k(x) = x \cdot \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k)$$

Bayes Classifier VS. LDA



LDA 입력 변수가 p>1개인 경우

Multivariate Gaussian(normal) Distribution



$$Var(X_1) = Var(X_2) Cor(X_1, X_2) = 0$$

Discriminant Function 모델링


$$X \sim N(\mu, \Sigma) \qquad \mathbf{Cov}(X) = \Sigma$$

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)$$

$$\qquad \qquad \mathbf{J}$$

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

Bayes Classifier VS. LDA



로지스틱이 있는데 왜 LDA?

1. Class가 많이 나눠진 경우,

2. 샘플 개수 n이 적으면서 입력 X 분포가 Gaussian과 흡사 할 때,

LDA가 로지스틱 보다 안정적!

QDA (Quadratic Discriminant Analysis)

LDA = Gaussian 분포 가정 + 베이즈 정리 이용하여 추정 +


공분산 동일

QDA = LDA – 공분산 동일
$$X \sim N(\mu_k, \Sigma_k)$$


$$\delta_k(x) = -\frac{1}{2}(x - \mu_k)^T \mathbf{\Sigma}_k^{-1}(x - \mu_k) + \log \pi_k$$

$$= -\frac{1}{2}x^T \mathbf{\Sigma}_k^{-1} x + x^T \mathbf{\Sigma}_k^{-1} \mu_k - \frac{1}{2}\mu_k^T \mathbf{\Sigma}_k^{-1} \mu_k + \log \pi_k$$


QDA VS. LDA VS. Bayes Classifier



선형 문제에 대한 예측 결과 에러 값 비교



비선형 문제에 대한 예측 결과 에러 값 비교



Thank you!