Build bioinformatics pipelines with Snakemake

2016.09.20 김가경

Snakemake References

- 1. 공식 documents
 https://bitbucket.org/snakemake/snakemake/wiki/Documentation
- 2. Johannes Köster and Sven Rahmann. *Snakemake--a scalable bioinformatics workflow engine.* Bioinformatics 2012, 28:2520-2522. Pubmed | PMC | <u>Journal</u>
- 3. Simple examples https://slowkow.com/notes/snakemake-tutorial/
- 4. 이인구님이 정리한 tutorial https://github.com/dlsrnsi/snakemake_tutorial
- 5. 고성능 병렬서버에서 snakemake 사용법 https://hpc.nih.gov/apps/snakemake.html
- 6. [BioPython 스터디 특강] Snakemake와 Joblib 소개
- 7 장혜린 학생 관련 발표자료

Basic rules

```
rule NAME:
  input: "path/to/inputfile", "path/to/other/inputfile"
  output: "path/to/outputfile", "path/to/another/outputfile"
  params: param1=param1, pram2=param2
  shell: "command --option1 {params.param1} --option2 {params.param2} {input}
  {output}"
```

shell 대신 python3 script를 실행할때는 "run:" 을 사용

Command line options

Option	Effect
-s FILE	실행시키는 파일 specify
-n	dryrun: execution plan만 확인
-р	print all shell commands
-F	input file 존재 여부와 상관없이 모든 rule 실행
-j [N]	사용 가능한 최대 core개수 설정 (default=1)
config [KEY=VALUE [KEY=VALUE]]	workflow 내에 config 값 변환 가능
-d DIR	working directory 설정
-c CMD	주어진 submit command 규칙을 따라 실행한다 (예: qsub)

Wild cards

```
$ snakemake -s EXAMPLE mapped_reads/A.bam
$ snakemake -s EXAMPLE mapped_reads/{A,B}.bam
```

Exercise following reference #3 (1)

Snakefile

```
SAMPLES = ['3C-629-2-1', '3C-629-2-2']
rule all:
  input:
     expand('{sample}.txt', sample=SAMPLES)
rule quantify_genes:
  input:
     genome = 'genome.fa',
     r1 = 'fastq/{sample}_R1.fastq.gz',
     r2 = 'fastq/{sample} R2.fastq.gz'
  output:
     '{sample}.txt'
  shell:
     'echo {input.genome} {input.r1} {input.r2} > {output}'
```

Exercise following reference #3 (2)

```
[kkkim@comet-ln2 snakemake-example]$ snakemake
Provided cores: 1
Rules claiming more threads will be scaled down.
Job counts:
       count jobs
                all
                quantify_genes
[kkkim@comet-ln2 snakemake-example]$ cat 3C-629-2-1.txt
genome.fa fastq/3C-629-2-1 R1.fastq.gz fastq/3C-629-2-1 R2.fastq.gz
```

Exercise following reference #3 (3) - Not working~! ππ

\$ snakemake --forceall --dag | dot -Tpng > dag1.png

Format: "png" not recognized. Use one of:

Exception ignored in: <_io.TextIOWrapper name='<stdout>' mode='w' encoding='ISO-8859-15'>

BrokenPipeError: [Errno 32] Broken pipe

\$ snakemake -dag > dag1.dot


dag1.dot

```
digraph snakemake_dag {
    graph[bgcolor=white, margin=0];
    node[shape=box, style=rounded, fontname=sans, fontsize=10, penwidth=2];
    edge[penwidth=2, color=grey];
    0[label = "all", color = "0.00 0.6 0.85", style="rounded,dashed"];
    1[label = "quantify_genes\nsample: 3C-629-2-1", color = "0.33 0.6 0.85", style="rounded,dashed"];
    2[label = "quantify_genes\nsample: 3C-629-2-2", color = "0.33 0.6 0.85", style="rounded,dashed"];
    2 -> 0
    1 -> 0
}
```


RNA-seq analysis

Expression (Gene, Transcript)
Alternative splicing
Fusion gene
Variant calling (SNPs, Indels)
Allele specific expression
..etc..

RNA-seq expression pipeline (1)



RNA-seq expression pipeline (2)



hisat2 alignment pipeline (1)

```
WDIR = "/home/kkkim/project/201604_RNAseq/"
workdir: WDIR
rule hisat2:
    input: fwd="1.raw/{sample}_1.fastq.gz", rev="1.raw/{sample}_2.fastq.gz"
    output: "3.aligned/hisat2/{sample}.sam"
    threads: 32
    params: GFF=GFF, Hisat2Index=Hisat2Index
    shell: """
         mkdir -p 3.aligned/hisat2
         hisat2 -t -p {threads} --dta-cufflinks --rna-strandness RF \
         --met-file 3.aligned/hisat2/{wildcards.sample}.metrics \
         -x {params.Hisat2Index} -1 {input.fwd} -2 {input.rev} \
         -S 3.aligned/hisat2/{wildcards.sample}.sam \
        2> 3.aligned/hisat2/{wildcards.sample}.stat
         11 11 11
```

hisat2 alignment pipeline (2)

```
rule sam2bam:
   input: "3.aligned/hisat2/{sample}.sam"
   output: "3.aligned/hisat2/{sample}.bam"
   threads: 32
   shell: samtools view -b -h -S -@ {threads} -O bam -o {output} {input}
rule sort bam:
   input: "3.aligned/hisat2/{sample}.sam"
   output: "3.aligned/hisat2/{sample}.sorted.bam"
   threads: 32
   shell: "samtools sort -@ {threads} -O bam -o {output} -T {output}.tmp {input}"
```

hisat2 alignment pipeline (3)

```
rule index_bam:
input: "3.aligned/hisat2/{sample}.sorted.bam"
output: "3.aligned/hisat2/{sample}.sorted.bam.bai"
shell: """
samtools sort -@ 32 -O bam -o {output} -T {input}.tmp
samtools index 3.aligned/hisat2/{sample}.sorted.bam
rm 3.aligned/hisat2/{sample}.sam
rm 3.aligned/hisat2/{sample}.bam
"""
```

장점

input, output 파일 형태를 파악하기 용이 전체 workflow의 visualization 가능 rule의 재활용이 용이 rule 속에 shell, python3, R 을 필요에 따라 직접 사용 가능 이미 input 파일이 만들어져 있는 경우, 다시 만들지 않고 그 파일 그대로 사용 단, input 파일이 output 파일보다 만들어진 시간이 나중일 경우에는 다시 rule을 execute: update된 input file이 있으면 그 단계부터 전개 project file을 configuration파일에서 설정: 최대한 pipeline자체를 변경하는 일이 없도록 함 configuration 파일을 변경하는 것 만으로 personalization 가능 final output을 만들기 위한 파일만 생성 :여러 개의 pipeline을 통합하여 운영가능 cluster environment에서 운영되도록 설계됨: 자동으로 어떤 rule들을 같이 실행시킬 수 있는지 파 악, 다수의 core에서 동시에 실행가능

출처 : 장혜린 학생 발표자료